Validation-First CPU/GPU Microbenchmarking of AES Implementations in the Context of Symmetric Cryptography Evolution

Marko Mihajlovic[1]

Abstract: This paper presents a validated and reproducible methodological framework for experimentally comparing cryptographic primitives and their implementations in a heterogeneous CPU/GPU environment. Starting from a DES/TDEA–AES retrospective, the study does not introduce a new cryptographic algorithm, but examines how implementation paths and measurement scope affect the interpretation of performance results. Particular emphasis is placed on a paired comparison between CPU AES-NI and CUDA AES-128 implementations, with a clear separation between isolated resident/kernel measurements and practical end-to-end pipelines that include host-device data transfers. The results show that GPU resident measurements can achieve high throughput for larger inputs, while the inclusion of transfer and synchronization costs changes the conclusion in favor of the AES-NI path in the tested environment. Reduced-keyspace and avalanche-effect demonstrations are used as controlled indicators of the limits of interpreting performance and security-related metrics.

Keywords: AES, DES, TDEA, AES-NI, CUDA, microbenchmarking, GPU, cryptographic performance, avalanche effect, reproducibility.

1 Introduction

Savremena primena kriptografskih algoritama ne zavisi samo od njihove matematičke definicije, već i od načina na koji su implementirani, od hardverske podrške na kojoj se izvršavaju i od metodologije kojom se meri njihova performansa. Isti algoritam može imati bitno različitu cenu u softverskoj implementaciji, uz hardversku akceleraciju instrukcijama procesora ili u GPU okruženju. Zbog toga poređenja zasnovana samo na jednoj vrednosti propusnosti često nisu dovoljna za pravilno tumačenje rezultata.

DES i TDEA imaju pre svega istorijski značaj: FIPS 46-3 i FIPS 81 su povučeni, dok je TDEA prema NIST preporukama u fazi ukidanja za savremenu upotrebu (National Institute of Standards and Technology, 1999; National Bureau of Standards, 1980; Barker & Mouha, 2017; Barker & Roginsky, 2019). AES ostaje centralni savremeni standard za simetrično šifrovanje (National Institute of Standards and Technology, 2023). Međutim, poređenje ovih algoritama ne može

[1] Singidunum University, Belgrade, Serbia; ORCID: 0009-0006-7979-0341

se svesti samo na brzinu. Neophodno je razlikovati veličinu ključa, veličinu bloka, režim rada, autentifikaciju, hardversku akceleraciju i obuhvat merenja. Režimi rada blokovskih šifara, uključujući CBC, CTR i GCM, dodatno menjaju značenje performansnog rezultata, jer ne obavljaju svi isti kriptografski posao (Dworkin, 2001; Dworkin, 2007).

Polazni problem ovog rada jeste pitanje kako metodološki korektno uporediti kriptografske primitive i njihove implementacije u savremenom heterogenom okruženju. U praksi se često susreću tvrdnje o visokoj GPU propusnosti koje se zasnivaju na izolovanom merenju kernela, bez uključivanja troškova prenosa podataka između hosta i uređaja. Sa druge strane, savremene CPU implementacije AES-a često koriste AES-NI instrukcije (Intel Corporation, 2012), zbog čega poređenje GPU implementacije samo sa softverskim CPU AES-om može dovesti do neadekvatnih zaključaka.

Doprinos rada je prvenstveno metodološki. Rad ne uvodi novi kriptografski algoritam, novu kriptoanalitičku metodu niti tvrdi da postiže state-of-the-art GPU performanse. Umesto toga, uspostavlja se validiran, ponovljiv i dokumentovan okvir za mikrobenchmarking kriptografskih primitiva. Okvir obuhvata validacione kapije pre merenja, smoke/pilot/study profile, fiksirane seedove, izvoz sirovih i agregiranih rezultata, dokumentovanje izvornog koda i agregaciju po nezavisnim sesijama.

Centralno mesto zauzima upareni protokol poređenja CPU AES-NI i CUDA AES-128 implementacije, uz jasno razdvajanje resident/kernel i end-to-end pipeline obuhvata. Fixed-key GPU propusnost nije isto što i brzina pretrage velikog broja ključeva; resident GPU rezultat nije isto što i aplikacioni end-to-end rezultat; avalanche efekat nije dokaz ukupne kriptografske sigurnosti. Upravo ova razdvajanja čine osnovni istraživački fokus rada.

2 Related Work and Research Gap

Prethodna istraživanja o AES izvršavanju na GPU platformama uglavnom se bave optimizacijom samog kernela i povećanjem propusnosti izolovanog šifarskog jezgra. Rani CUDA radovi i specifikacije režima rada podržavaju izbor ECB i CTR režima kao pogodnih kandidata za paralelizaciju, jer se blokovi mogu obrađivati nezavisno, dok CBC enkripcija sadrži zavisnost između susednih blokova (Dworkin, 2001; Iwai, Nishikawa, & Kurokawa, 2012). Iwai, Nishikawa i Kurokawa (2012) analizirali su AES implementaciju na CUDA GPU platformi i razmatrali i varijante u kojima se obrada preklapa sa transferom podataka. Savremeniji radovi idu dalje ka T-table, shared-memory, bitsliced i low-level optimizacijama. Tezcan (2021), na primer, pokazuje da pažljivo uklanjanje shared-memory bank konflikata može dovesti do veoma visokih AES-128 propusnosti na RTX

2070 Super GPU-u.

Takvi radovi su važni za razumevanje gornjih granica GPU AES performansi, ali često odgovaraju na drugačije pitanje od ovog rada. U fokusu optimizacionih radova najčešće je maksimalna device-resident ili kernel-only propusnost, često na snažnijem GPU hardveru, uz drugačije merne obuhvate i drugačije CPU reference. Nasuprot tome, praktično poređenje CPU i GPU izvršavanja zahteva da se jasno odvoje dve metrike: izolovano računanje nad podacima koji su već na GPU-u i kompletan host-driven tok koji uključuje H2D transfer, kernel, D2H transfer i sinhronizaciju. Bez te razlike, GPU rezultat može izgledati značajno povoljnije nego što jeste u aplikacionom scenariju.

Istraživački jaz ovog rada nalazi se upravo u tom razdvajanju. Rad ne pokušava da reprodukuje rekordne CUDA AES implementacije niti da uvede novu optimizacionu tehniku. Umesto toga, cilj je da se u jedinstvenom i validiranom protokolu uporede softversko CPU izvršavanje, CPU AES-NI, CUDA baseline i laka CUDA optimizacija, pri čemu se posebno prijavljuju rezidentno merenje na uređaju, odnosno izolovano merenje kernela (*resident/kernel-only*) i end-to-end pipeline rezultati. Time se doprinos pomera sa pitanja „koji je najbrži kernel" na pitanje „šta se realno meri kada se različite kriptografske putanje porede pod istim eksperimentalnim pravilima".

Ovakvo pozicioniranje je posebno važno zato što AES-NI predstavlja snažnu savremenu CPU referencu. Poređenje GPU implementacije samo sa softverskim CPU AES-om može preceniti praktičan dobitak GPU-a. Zato ovaj rad koristi AES-NI kao primarnu CPU referencu u uparenom CPU–GPU eksperimentu, dok se softverski CPU AES zadržava kao sekundarna i retrospektivna putanja. Na taj način se GPU performanse ne posmatraju izolovano, već u odnosu na realističniju savremenu CPU akceleraciju.

3 Methodology

Eksperimentalna platforma obuhvata Intel Core i5-10300H procesor, 16 GB RAM-a i NVIDIA GeForce GTX 1650 Ti GPU sa 4096 MiB VRAM-a. Korišćeni su Windows 10, Python 3.12, PyCryptodome, CuPy i CUDA runtime. GPU okruženje radi u WDDM režimu, što je relevantno za tumačenje host-driven GPU merenja, predaje komandi, sinhronizacije i mogućih režijskih troškova. PyCryptodome je korišćen kao kriptografska biblioteka za CPU eksperimente i referentne provere, pri čemu se rezultati tumače kao performanse konkretnih bibliotečkih putanja, a ne kao univerzalne performanse algoritama (PyCryptodome, n.d.). U ovom radu se WDDM tretira samo kao mogući izvor sistemske varijabilnosti, bez tvrdnje da je izolovani uzrok izmerenih razlika (Microsoft, n.d.-a; NVIDIA Corporation, n.d.-a).

Primenjen je pristup *validation-first*: poznati test vektori i funkcionalne provere prethode merenju. Neuspešna validacija zaustavlja eksperiment. Smoke provere ispituju funkcionalnost i izvoz, pilot služi proveri protokola, a finalne tabele koriste study sesije. Sesije imaju dokumentovane seedove, argumente i broj ponavljanja; zagrevanje ne ulazi u statistiku. Metadata, validation, raw i summary zapisi, prateći izveštaji i source snapshot/hash vrednosti omogućavaju sledljivost.

Primarni CPU tajmer je monotoni `perf_counter_ns()`. Za N obrađenih bajtova i zidno vreme T u sekundama propusnost je:

$$R = \frac{N}{10^6 T}, \tag{1}$$

u decimalnim MB/s. CPU transform-only merenja uključuju transformacioni poziv, ali ne obavezno punu aplikacionu cenu. CUDA resident meri kernel nad podacima već pripremljenim na uređaju, dok pipeline uključuje pinned H2D → kernel → D2H tok. Pinned memorija i CUDA događaji koriste se u skladu sa preporukama za merenje CUDA performansi (NVIDIA Corporation, n.d.-c; CuPy, n.d.-a).

Glavne performansne vrednosti agregiraju se kao medijane pet sesijskih medijana, bez objedinjavanja raw raspodela i bez uklanjanja ekstremnih vrednosti. Faktori ubrzanja računaju se po sesijskim odnosima medijana vremena. Ovakav okvir sprečava mešanje različitih obuhvata merenja: izolovani kernel, kompletan pipeline i CPU transformacija nisu ista metrika.

Stabilnost rezultata procenjivana je kroz pet nezavisnih study sesija sa različitim seedovima. Run-to-run varijabilnost analizirana je na nivou sesijskih medijana, pri čemu se standardna devijacija i raspon koriste kao opisne mere stabilnosti, a ne kao formalni intervali poverenja. Zbog toga se termin ponovljivost u ovom radu odnosi na dokumentovan i ponovljiv eksperimentalni protokol, validacione zapise i stabilnost agregiranih sesijskih rezultata, a ne na statističku generalizaciju na druge platforme.

4 Results

4.1 CPU poređenja DES/TDEA/AES i AES-NI akceleracija

Prvi eksperimenti postavljaju istorijsko i implementaciono polazište. DES, troključni TDEA i AES-128/192/256 poređeni su u CBC režimu bez padding-a. DES/TDEA rezultati imaju retrospektivnu funkciju, jer ovi algoritmi nisu preporuka za novu zaštitu podataka. AES se zatim meri softverski i uz AES-NI putanju. Validacija koristi poznate CBC test vektore iz standardizovanih izvora (National Bureau of Standards, 1980; Dworkin, 2001).

Table 1
CPU performanse CBC i AES-NI eksperimenata. Propusnost je izražena u decimalnim MB/s; prikazane su agregirane medijane study sesija.

Eksperiment	Algoritam / operacija	Software	AES-NI	Faktor
CBC, 10 MiB enc.	DES	87.4	–	–
CBC, 10 MiB enc.	TDEA	32.6	–	–
CBC, 10 MiB enc.	AES-128	223.8	–	–
CBC, 10 MiB enc.	AES-192	198.9	–	–
CBC, 10 MiB enc.	AES-256	174.6	–	–
AES-NI, 10 MiB enc.	AES-128	225.1	531.6	2.37×
AES-NI, 10 MiB dec.	AES-128	223.7	557.2	2.47×
AES-NI, 10 MiB enc.	AES-192	198.5	504.3	2.53×
AES-NI, 10 MiB dec.	AES-192	195.5	517.8	2.65×
AES-NI, 10 MiB enc.	AES-256	174.9	474.0	2.71×
AES-NI, 10 MiB dec.	AES-256	171.4	480.4	2.80×

Rezultati pokazuju očekivanu razliku između istorijskih i savremenih implementacija. AES varijante u softverskom CBC režimu znatno su brže od TDEA, dok se AES-NI akceleracijom postiže dodatno ubrzanje od približno 2.4–2.8 puta u korišćenoj biblioteci, veličinama ulaza i definisanom mernom obuhvatu. Ovi faktori zavise od implementacije biblioteke, veličine ulaza i metodologije merenja, pa se ne tumače kao univerzalni AES-NI faktori. Ovi faktori ne predstavljaju meru sigurnosti, već cenu konkretne implementacione putanje. Veći broj rundi kod AES-192 i AES-256 smanjuje softversku propusnost, ali AES-NI značajno menja praktičnu cenu izvršavanja.

4.2 AES-GCM kao savremeni AEAD režim

AES-GCM proširuje analizu na autentifikovanu enkripciju. Eksperiment koristi AES-128-GCM i AES-256-GCM, 96-bitni nonce, 128-bitni tag i fiksni AAD od 16 bajtova, uz validaciju tag-a i odbijanje izmenjenog šifrata, tag-a ili AAD-a. GCM nije direktna zamena za CBC u smislu istog posla: pored poverljivosti, uključuje i autentifikaciju (Dworkin, 2007).

Kod malih ulaza dominiraju fiksni troškovi, dok se na 1 MiB i većim ulazima AES-128-GCM kreće oko 1.13–1.19 GB/s, a AES-256-GCM oko 1.06–1.10 GB/s. Rezultat potvrđuje da savremeni režimi rada zahtevaju pažljivo tumačenje: CBC i GCM propusnosti ne predstavljaju istu funkcionalnost, pa se ne smeju tumačiti kao izolovana cena istog kriptografskog zadatka.

Table 2
Propusnost AES-GCM autentifikovane enkripcije na CPU AES-NI putanji. Propusnost je izražena u decimalnim MB/s.

Veličina	Algoritam	Enkripcija	Dekripcija
1 KiB	AES-128-GCM	70.6	38.1
1 KiB	AES-256-GCM	70.1	38.0
1 MiB	AES-128-GCM	1148.2	1131.4
1 MiB	AES-256-GCM	1059.3	1059.8
100 MiB	AES-128-GCM	1179.7	1189.3
100 MiB	AES-256-GCM	1100.4	1080.4

4.3 CUDA baseline i upareno CPU–GPU poređenje

CUDA AES-128 baseline koristi čitljivi bajtovski kernel, jednu nit po 16-bajtnom AES bloku i 128 niti po CUDA bloku. ECB je korišćen isključivo kao mikrobenchmark nezavisnih blokova, dok CTR omogućava paralelizabilnu transformaciju definisanu u SP 800-38A (Dworkin, 2001). GPU implementacija se oslanja na CUDA/CuPy mehanizme za korisničke CUDA kernele i merenje događajima (NVIDIA Corporation, n.d.-b; CuPy, n.d.-a; CuPy, n.d.-b; Okuta et al., 2017).

Centralni eksperiment poredi CPU software, CPU AES-NI, CUDA baseline i laki kandidat CUDA v1 u istom ECB/CTR protokolu. Za svaki režim, veličinu i ponavljanje koriste se isti plaintext, ključ i početni CTR brojač. Ključna metodološka vrednost eksperimenta nije samo u faktorima ubrzanja, već u razdvajanju dva pitanja: kolika je propusnost izolovanog GPU jezgra kada su podaci već na uređaju, i kolika je praktična propusnost kada se uključe transferi i sinhronizacija.

Table 3
Finalno upareno AES-128 CPU–GPU poređenje, u decimalnim MB/s. K označava resident kernel-only, E2E end-to-end pipeline.

		CPU		CUDA baseline		CUDA v1	
Režim	Veličina	Soft.	AES-NI	K	E2E	K	E2E
ECB	1 MiB	275.7	1793.5	4901.1	1339.1	5149.3	1320.1
ECB	16 MiB	280.5	1904.8	3667.5	1080.0	3424.4	866.2
ECB	32 MiB	282.1	1909.9	4753.5	1202.0	4792.6	1214.5
CTR	1 MiB	257.4	1381.7	5017.1	1313.1	4853.9	1291.0
CTR	16 MiB	264.3	1446.5	3655.6	1103.1	3576.2	1074.0
CTR	32 MiB	266.3	1455.8	4800.6	1204.5	4877.7	1209.1

Resident GPU rezultati nadmašuju CPU AES-NI za veće ulaze, ali pipeline rezultati ne. Na primer, kod CTR 1 MiB resident baseline daje 5017.1 MB/s, dok end-to-end pipeline daje 1313.1 MB/s, ispod CPU AES-NI rezultata od 1381.7 MB/s. Na 32 MiB CTR resident rezultat je 4800.6 MB/s, ali pipeline ostaje 1204.5 MB/s, dok je CPU AES-NI 1455.8 MB/s. Time se pokazuje da resident i end-to-end merenja odgovaraju različitim istraživačkim pitanjima.

Table 4
Faktori prema CPU AES-NI: medijane pet sesijskih odnosa vremena. I označava resident/isolated, P end-to-end pipeline; vrednost veća od jedan označava kraće GPU vreme.

Režim	Veličina	Baseline I	v1 I	Baseline P	v1 P
ECB	1 MiB	2.65	2.91	0.75	0.77
ECB	16 MiB	1.89	1.77	0.58	0.42
ECB	32 MiB	2.50	2.52	0.63	0.64
CTR	1 MiB	3.66	3.54	0.95	0.91
CTR	16 MiB	2.58	2.51	0.75	0.74
CTR	32 MiB	3.30	3.40	0.82	0.83

Svi pipeline faktori ostaju ispod jedan. Najbliži je CTR 1 MiB sa 0.95, dok su na 32 MiB CTR faktori 0.82–0.83, a ECB 0.63–0.64. Laka CUDA optimizacija v1 ne daje dosledno poboljšanje: u nekim resident slučajevima rezultat raste, ali u ECB 16 MiB pipeline opada. Ovo pokazuje da optimizacija jezgra ne mora automatski poboljšati aplikacioni tok, jer transferi, sinhronizacija i runtime troškovi mogu promeniti zaključak.

4.4 Redukovani prostor ključeva i avalanche demonstracija

Demonstracija redukovanog prostora ključeva koristi AES-128 ECB sa softverskom putanjom i promenljivih 24 bita ključa. Tajmer uključuje formiranje ključa, novi cipher/key schedule, enkripciju dva bloka, alokaciju, poređenje i stop-on-match kontrolu. Cilj nije optimizovana pretraga punog prostora, već ilustracija eksponencijalnog rasta iscrpne pretrage.

End scenario obilazi ceo redukovani prostor za oko 109 s pri 153.9 hiljada kandidata/s i jedini je osnov za linearne ekstrapolacije. Međutim, ta stopa nije DES/TDEA/GPU stopa, niti procena paralelnih farmi, ASIC/FPGA ili specifičnih kriptoanalitičkih napada. Double-DES meet-in-the-middle menja model napada i zahteva poseban protokol vremena, memorije i lažnih pogodaka, pa nije uključen u ovu studiju.

Avalanche demonstracija meri Hammingovo rastojanje između osnovnog bloka šifrata i bloka dobijenog nakon promene jednog bita plaintext-a ili jednog

Table 5
CPU demonstracija pretraživanja redukovanog 24-bitnog prostora AES-128 ključeva.

Scenario	Kandidati	Vreme (s)	Kandidata/s
start	1	0.0000088	113 636
middle	8 388 609	54.38	154 263
end	16 777 216	109.01	153 903
random	6 800 733	43.00	154 079

efektivnog bita ključa. Ideja difuzije prati klasično razumevanje rasprostiranja statističke zavisnosti u kriptografskim sistemima (Shannon, 1949). Rezultat se normalizuje veličinom bloka: 64 bita za DES/TDEA i 128 bita za AES.

Table 6
Raspodele avalanche efekta pri promeni jednog bita otvorenog teksta (P) ili efektivnog ključa (K).

Algoritam	Var.	Blok	Med. HD	Pros. HD	Med. norm.	Pros. norm.
DES	P	64	32	32.02	0.50	0.5003
DES	K	64	32	31.94	0.50	0.4990
TDEA	P	64	32	31.97	0.50	0.4995
TDEA	K	64	32	32.02	0.50	0.5004
AES-128	P	128	64	63.99	0.50	0.4999
AES-128	K	128	64	63.99	0.50	0.4999
AES-192	P	128	64	64.03	0.50	0.5002
AES-192	K	128	64	64.09	0.50	0.5007
AES-256	P	128	64	63.98	0.50	0.4998
AES-256	K	128	64	64.00	0.50	0.5000

DES/TDEA medijana je 32 od 64 bita, a AES medijana 64 od 128 bita, odnosno 0.5 u svih deset grupa. Normalizovani proseci su približno 0.4990–0.5007. Ovo je očekivan pokazatelj lokalne difuzije, ali nije dokaz kriptografske sigurnosti, kompletan SAC/BIC test niti osnov za rangiranje algoritama.

5 Discussion

Placeholder discussion. Interpret the eventual results and describe their limitations and implications.

6 Conclusion

U radu je prikazan validiran i ponovljiv metodološki okvir za mikrobenchmarking kriptografskih primitiva u heterogenom CPU/GPU okruženju. Osnovni doprinos nije u novom algoritmu ili kriptoanalitičkoj metodi, već u eksperimentalnoj organizaciji koja razdvaja validaciju, obuhvat merenja, agregaciju rezultata i granice tumačenja. Takav pristup omogućava da se performanse DES/TDEA–AES familije algoritama i njihovih implementacija tumače u kontekstu konkretne platforme.

Rezultati potvrđuju da izbor obuhvata merenja presudno utiče na zaključak. AES-NI značajno smanjuje cenu AES izvršavanja na CPU-u. CUDA AES-128 može postići visoku resident/kernel propusnost kada su podaci već dostupni na uređaju, ali u praktičnom end-to-end pipeline scenariju prednost izolovanog GPU kernela nestaje u testiranom okruženju. Time se pokazuje da resident i end-to-end merenja odgovaraju različitim istraživačkim pitanjima.

Pokušaj lake CUDA optimizacije dodatno pokazuje da optimizacija kernela ne mora automatski dovesti do boljeg aplikacionog rezultata. Poboljšanje izolovanog koda može biti poništeno memorijskim ponašanjem, redosledom rada, transferima ili drugim sistemskim troškovima. Zbog toga GPU performanse treba analizirati u dva sloja: kao računarsku propusnost jezgra i kao propusnost celokupnog toka podataka.

Demonstracija redukovanog prostora ključeva i avalanche analiza dopunjuju performansni deo rada, ali su ograničene u tumačenju. Redukovani prostor ključeva ilustruje eksponencijalni rast iscrpne pretrage, bez tvrdnje o napadu na pune prostore. Avalanche rezultati pokazuju očekivanu raspodelu promene oko polovine bloka, ali ne predstavljaju dokaz ukupne sigurnosti.

Budući rad može ići u dva pravca. Prvi je dublja GPU optimizacija AES kernela, uključujući shared-memory T-table dizajne sa kontrolom bank konflikata, bitsliced/PTX implementacije i detaljnije merenje occupancy-ja, register pressure-a i memorijskih obrazaca. Drugi pravac je optimizacija samog pipeline-a, kroz chunking, `cudaMemcpyAsync`, non-default stream-ove i preklapanje transfera i računanja, što NVIDIA dokumentacija i tehnički blogovi navode kao uslovljeno pinned memorijom, asinkronim kopiranjem i odgovarajućim stream-ovima (NVIDIA Corporation, n.d.-c; Harris, 2012). Ovaj drugi pravac je posebno relevantan za rezultate ovog rada, jer finalno poređenje pokazuje da transferni i runtime troškovi mogu poništiti resident dobitak kernela. Dodatno, merenja na Linux/TCC okruženju, uz praćenje takta, temperature, potrošnje i Nsight Systems tragova, omogućila bi jasnije razdvajanje algoritamskih, drajverskih i sistemskih efekata.

Najvažniji zaključak rada jeste da se kriptografske performanse ne mogu

korektno tumačiti bez jasnog metodološkog okvira. Fixed-key throughput nije candidate-check stopa; resident GPU rezultat nije aplikacioni end-to-end rezultat; difuzija nije sigurnosni dokaz. Validacioni postupci, upareni protokoli, dokumentovani seedovi, metapodaci i agregacija po sesijama čine osnovu reproduktivnog poređenja kriptografskih implementacija.

7 Acknowledgments

Placeholder acknowledgments. Replace with appropriate funding or support information, or remove the paragraph if no acknowledgments are needed.

References

[1] Elaine Barker and Nicky Mouha. Recommendation for the triple data encryption algorithm (tdea) block cipher. NIST Special Publication 800-67 Rev. 2, National Institute of Standards and Technology, 2017.

[2] Elaine Barker and Allen Roginsky. Transitioning the use of cryptographic algorithms and key lengths. NIST Special Publication 800-131A Rev. 2, National Institute of Standards and Technology, 2019.

[3] CuPy. Performance best practices. `https://docs.cupy.dev/en/stable/user_guide/performance.html`, n.d.. Accessed 2026.

[4] CuPy. cupy.rawkernel. `https://docs.cupy.dev/en/stable/reference/generated/cupy.RawKernel.html`, n.d.. Accessed 2026.

[5] Morris Dworkin. Recommendation for block cipher modes of operation: Methods and techniques. NIST Special Publication 800-38A, National Institute of Standards and Technology, 2001.

[6] Morris Dworkin. Recommendation for block cipher modes of operation: Galois/counter mode (gcm) and gmac. NIST Special Publication 800-38D, National Institute of Standards and Technology, 2007.

[7] Mark Harris. How to overlap data transfers in cuda c/c++. NVIDIA Technical Blog, 2012. URL `https://developer.nvidia.com/blog/how-overlap-data-transfers-cuda-cc/`.

[8] Intel Corporation. Intel advanced encryption standard instructions (aes-ni), 2012. URL `https://www.intel.com/content/www/us/en/developer/articles/technical/advanced-encryption-standard-instructions-aes-ni.html`.

[9] Keisuke Iwai, Naoki Nishikawa, and Takakazu Kurokawa. Acceleration of aes encryption on cuda gpu. *International Journal of Networking and Computing*, 2(1):131–145, 2012. doi: 10.15803/ijnc.2.1_131.

[10] Microsoft. Gpu preemption. Microsoft Learn, n.d.. URL `https://learn.microsoft.com/en-us/windows-hardware/drivers/display/gpu-preemption`. Accessed 2026.

[11] Microsoft. Timeout detection and recovery (tdr). Microsoft Learn, n.d.. URL `https://learn.microsoft.com/en-us/windows-hardware/drivers/display/timeout-detection-and-recovery`. Accessed 2026.

[12] National Bureau of Standards. Des modes of operation. Federal Information Processing Standards Publication 81, National Bureau of Standards, 1980. URL `https://csrc.nist.`

gov/pubs/fips/81/final.

[13] National Institute of Standards and Technology. Data encryption standard (des). Federal Information Processing Standards Publication 46-3, National Institute of Standards and Technology, 1999. URL https://csrc.nist.gov/pubs/fips/46-3/final.

[14] National Institute of Standards and Technology. Advanced encryption standard (aes). Federal Information Processing Standards Publication 197, Update 1, National Institute of Standards and Technology, 2023.

[15] NVIDIA Corporation. Cuda installation guide for microsoft windows, n.d.. URL https://docs.nvidia.com/cuda/cuda-installation-guide-microsoft-windows/. Accessed 2026.

[16] NVIDIA Corporation. Cuda c++ programming guide, n.d.. URL https://docs.nvidia.com/cuda/cuda-c-programming-guide/. Accessed 2026.

[17] NVIDIA Corporation. Cuda c++ best practices guide, n.d.. URL https://docs.nvidia.com/cuda/cuda-c-best-practices-guide/. Accessed 2026.

[18] Ryosuke Okuta, Yuya Unno, Daisuke Nishino, Shohei Hido, and Crissman Loomis. Cupy: A numpy-compatible library for nvidia gpu calculations. In *Proceedings of Workshop on Machine Learning Systems (LearningSys) in NeurIPS 2017*, 2017. URL https://cupy.dev/.

[19] PyCryptodome. Pycryptodome documentation, n.d. URL https://pycryptodome.readthedocs.io/. Accessed 2026.

[20] Claude E. Shannon. Communication theory of secrecy systems. *Bell System Technical Journal*, 28(4):656–715, 1949. doi: 10.1002/j.1538-7305.1949.tb00928.x.

[21] Cihangir Tezcan. Optimization of advanced encryption standard on graphics processing units. *IEEE Access*, 9:67315–67326, 2021. doi: 10.1109/ACCESS.2021.3077551.